



## **Curso Demografía - Licenciatura en Estadística, UDELAR**

---

**Daniel Ciganda**


Clase 15

11 de Noviembre de 2024

Pasos a seguir:


- Obtener una distribución de tasas específicas por edad \*condicionales\* del evento en cuestión
- Utilizar estas tasas como un modelo de riesgo constante a intervalos (edades) del evento
- Invertir la función de riesgo acumulado para obtener realizaciones (números aleatorios) de nuestra distribución de partida
- Vincular ambos procesos en un modelo de simulación de eventos discretos que represente las trayectorias de las mujeres de una cohorte

$$m_x = \frac{D_x}{L_x}$$



**Figure 1:** Tasas de Mortalidad por Edad de una Cohorte

$$f_{i,x} = \frac{B_{i,x}}{L_{i-1,x}}$$



**Figure 2:** Tasas Condicionales de Fecundidad por Edad de una Cohorte - Primer Hijo

## Pasos a seguir:

- Obtener una distribución de tasas específicas por edad condicionales del evento en cuestión
- Utilizar estas tasas como un modelo de **riesgo constante** a intervalos (edades) del evento
- Invertir la función de riesgo acumulado para obtener realizaciones (números aleatorios) de nuestra distribución de partida
- Vincular ambos procesos en un modelo de simulación de eventos discretos que represente las trayectorias de las mujeres de una cohorte

Variable Aleatoria  $T > 0$  , continua

Función de Distribución:  $F(t) = P(T \leq t)$

Función de Supervivencia:  $S(t) = 1 - F(t)$

Densidad:  $f(t) = F'(t)$

Hazard:

$$h(t) = \lim_{\Delta t \rightarrow 0} \frac{P(t \leq T < t + \Delta t \mid T \geq t)}{\Delta t} = \frac{f(t)}{S(t)}$$

Además:


$$H(t) = \int_0^t h(s) ds$$

$$S(t) = \exp\{-H(t)\}$$

Cuando asumimos que el riesgo es **constante** en cada intervalo de edad, el vector de tasas de ocurrencia/exposición por edad observadas representa la **función de riesgo** que caracteriza a la variable aleatoria *tiempo al evento*.

Esto es así ya que, bajo el supuesto de riesgo constante, el Estimador de Máxima Verosimilitud (**EMV**) del riesgo de un evento es la cantidad de eventos observados sobre el tiempo de exposición al riesgo del evento, es decir la tasa de ocurrencia/exposición.

Vamos a ilustrar esta idea a través de un ejemplo.



**Figure 3:** Seguimiento de 4 individuos en un estudio longitudinal. La primera persona abandona el estudio antes de morir o cumplir 41 años. La segunda y tercera persona fallecen antes de cumplir 41 años de edad. La cuarta observación también es censurada, pero en este caso porque la persona alcanza su 41 cumpleaños.



## Ejemplo: Mortalidad de una cohorte en edades 40-41

En un estudio, se observó la **edad exacta de muerte** de individuos en el intervalo de edad de 40 a 41 años:

- $x_i$  = **edad hasta la que se observa** a cada individuo  $i$ .
- $d_i$  es un **indicador**:  $d_i = 1$  si el individuo murió,  $d_i = 0$  si no tenemos información sobre su muerte en ese intervalo (datos censurados).

Nuestro objetivo es derivar el EMV para el riesgo de muerte **bajo la distribución exponencial** en este contexto específico.

## Ejemplo: Mortalidad de una cohorte en edades 40-41

Bajo el supuesto de que nuestros tiempos a la muerte se distribuyen de acuerdo a la distribución exponencial, la función de riesgo es:

$$h(x) = \lambda$$

La función de supervivencia es:

$$S(x) = e^{-\lambda x}$$

Y la función de densidad para el tiempo a la muerte (luego de los 40) es:

$$f(x) = \lambda e^{-\lambda x}$$

Para cada individuo:

- Si  $d_i = 1$ : contribución a la verosimilitud =  $f(x_i)$
- Si  $d_i = 0$ : contribución a la verosimilitud =  $S(x_i)$

Por lo tanto, la función de verosimilitud está dada por:

$$L(\lambda) = \prod_{i=1}^n \left( \lambda e^{-\lambda x_i} \right)^{d_i} \left( e^{-\lambda x_i} \right)^{1-d_i}$$

Tomando la log-verosimilitud:

$$\ell(\lambda) = \sum_{i=1}^n [d_i \log(\lambda) - \lambda x_i]$$

Diferenciando respecto a  $\lambda$  e igualando a cero:

$$\frac{d\ell}{d\lambda} = \sum_{i=1}^n \left[ \frac{d_i}{\lambda} - x_i \right] = 0$$

Esto nos da:

$$\hat{\lambda} = \frac{\sum d_i}{\sum x_i}$$

EMV del riesgo de muerte:

$$\frac{\text{numero total de muertes}}{\text{tiempo total de exposición al riesgo de morir}} = \frac{D_x}{L_x} = m_x$$

## Pasos a seguir:

- Obtener una distribución de tasas específicas por edad condicionales del evento en cuestión
- Utilizar estas tasas como un modelo de riesgo constante a intervalos (edades) del evento
- Obtener la función de riesgo acumulado  $H(t)$ . Invertir  $H(t)$  para obtener realizaciones (tiempos de espera) de nuestra distribución de partida
- Vincular ambos procesos en un modelo de simulación de eventos discretos que represente las trayectorias de las mujeres de una cohorte

# Método de Inversión - Función de Riesgo Acumulado

Podemos obtener realizaciones de  $T$  a partir de la función de riesgo acumulado  $H(t)$  con:

$$T = H^{-1}(-\log U)$$

Podemos obtener realizaciones de  $X$ :

- Generando valores aleatorios

$$u_1, \dots, u_n \sim U(0, 1)$$


- Transformarlos

$$H^{-1}(-\log u_i) = t_i$$

Podemos invertir  $H(t)$

$$H(t_i) = -\log u_i \quad \Rightarrow \quad H(t_i) + \log u_i = 0$$

En R: `uniroot()`



# El Estimador Kaplan-Meier de la Función Supervivencia

- Método no paramétrico para estimar la función de supervivencia.
- Tiene en cuenta datos censurados.
- La probabilidad de supervivencia en el tiempo  $t$  es un producto de probabilidades condicionales.

Para cada tiempo  $t_i$ :

$$S(t_i) = \frac{n_i - d_i}{n_i}$$

Donde:

- $S(t)$ : Probabilidad estimada de supervivencia en el tiempo  $t$ .
- $d_i$ : Número de eventos en el tiempo  $t_i$ .
- $n_i$ : Número en riesgo justo antes del tiempo  $t_i$ .

La probabilidad acumulada de supervivencia hasta el tiempo  $t$  es:

$$S(t) = \prod_{i:t_i \leq t} \left( \frac{n_i - d_i}{n_i} \right)$$



## Ejemplo: Datos de tiempo a la Muerte

Consideremos un conjunto de datos de tiempo hasta la muerte o último seguimiento:

Individuo	Tiempo (meses)	Evento
1	2	1
2	4	1
3	6	0
4	8	0
5	10	1
6	11	1
7	12	0
8	15	1
9	18	0
10	20	1

Donde "Evento" es una variable binaria: 1 indica muerte y 0 indica que la observación fue censurada en el último seguimiento.

Para cada tiempo  $t$  único donde ocurre un evento:

- Determine  $n$ , el número de individuos en riesgo justo antes de  $t$ .
- Determine  $d$ , el número de eventos (muertes) en  $t$ .
- Calcule  $S(t)$  usando:

$$S(t) = \prod_{i:t_i \leq t} \left( \frac{n_i - d_i}{n_i} \right)$$

Tiempo (meses)	Evento	Cálculo	S(t)
2	muerte	$1.0000 \times (1 - \frac{1}{10})$	0.9000
4	muerte	$0.9000 \times (1 - \frac{1}{9})$	0.8000
6	censurado	$0.8000 \times (1 - \frac{0}{8})$	0.8000
8	censurado	$0.8000 \times (1 - \frac{0}{7})$	0.8000
10	muerte	$0.8000 \times (1 - \frac{1}{6})$	0.6667
11	muerte	$0.6667 \times (1 - \frac{1}{5})$	0.5333
12	censurado	$0.5333 \times (1 - \frac{0}{4})$	0.5333
15	muerte	$0.5333 \times (1 - \frac{1}{3})$	0.3556
18	censurado	$0.3556 \times (1 - \frac{0}{2})$	0.3556
20	muerte	$0.3556 \times (1 - \frac{1}{1})$	0.0000

**Table 1:** Estimador Kaplan-Meier.

**Kaplan–Meier Survival Curve**

